

Modelovanie softvéru autonómnych aut*

Peter Bartoš

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií
xbartos20@stuba.sk

2. november 2021

Abstrakt

Prvý príchod aut sa datuje už ďaleko do minulosti a všeobecný fakt je, že nám umožnil zdolávať pomerne dlhé vzdialenosti za oveľa kratší čas. Táto zvýšená rýchlosť nám skrátila čas na spracovávanie informácií a tým zväčšila šancu ohroziť a poškodiť naše okolie počas riadenia tohto vozidla. Tiež vieme, že človek nedokáže konkurovať počítaču pri rýchlosti spracúvania informácií. Tak prečo nie autonómne autá? Funkcie auta by boli ovládané počítačom alebo umelou inteligenciou, ktoré by rozhodovali kedy pridať plyn alebo brzdiť, kedy sa preradiť do iného pruhu alebo kedy zastaviť na prechode pre chodcov. Prototypy týchto aut už v dnešnej dobe existujú a tento článok analyzuje ich modelovanie v oblasti softvérového inžinierstva.

1 Úvod

Podľa štúdií National Highway Traffic Safety Administration (NHTSA) [12] sa do hlavných dôvodov autonehôd zahŕňajú poruchy vozidiel, pochybenie vodiča, environmentálne faktory a neznáme príčiny. Vodiči zapríčinia okolo 94% autonehôd. Ďalej sa to delí do kategórie vozidiel, ktoré zapríčínajú 2% nehôd. Nasledujú environmentálne faktory zahŕňajú tiež 2% škôd. Na poslednom mieste sú faktory neznámych príčin, ktoré sa pohybujú okolo 2%. Z týchto informácií je možné vydedukovať, že 94% takýchto nešťastí zmizne vďaka odbremeneniu vodičov od riadenia vozidla a zavedenia autonómnych aut do každodenného života ľudí. Treba sa teda pozrieť hlbšie a zanalyzovať ako fungujú a operujú autonómne autá. Článok rozpracuje úrovne automatizácie autonómneho auta[2], systémy autonómie[3], ich fungovanie[3.1], ich funkcie[3.2], ako operuje autonómne auto[4] a zhrnutie týchto informácií na záver[5].

2 Úrovne automatizácie jazdy

Existuje 6 úrovní delenia automatizovanej jazdy. [18] Tieto úrovne sa delia do dvoch skupín, kde prevažne človek monitoruje prostredie jazdy a kde prevažne

*Semestrálny projekt v predmete Metódy inžinierskej práce, ak. rok 2021/22, vedenie: Vladimír Mlynarovič

Tabuľka 1: Tabuľka úrovni delenia automatizovanej jazdy [18] [2]

Nulová automatizácia	Assistencia vodiča	Čiastočná automatizácia	Prípadná automatizácia	Vysoká automatizácia	Úplná automatizácia
Úplna manuálna kontrola vodiča	Vozidlo má jediný automatizovaný systém - tempomat	Čiastočná automatizácia pomocou systému ADAS	Schopnosť detekcie prostredia, informované rozhodnutia, nevyhnutná kontrola vodiča a jeho zasiahnutie	Schopnosť samoriadenia len v určitých podmienkach obmedzované legislatívou, človek má stále možnosť ovládať auto	Nepotrebuje kontrolu a človek nemá možnosť zasiahnuť
Človek monitoruje jazdné prostredie			Systém monitoruje jazdné prostredie		

systém monitoruje prostredie jazdy. Každá úroveň taktiež popisuje rolu vodiča a rolu systému, ktorá sa týka ovládania riadiacich funkcií auta. Prvá úroveň je úplna manuálna kontrola vodiča, kde človek vykonáva všetky riadiace úkony, ako zabáčanie, brzdenie, prídávanie a pod. [18] Druhá úroveň obsahuje jeden automatizovaný systém a tým je tempomat. Tretia úroveň zahŕňa čiastočnú automatizáciu. Systém ADAS[3.1] sa stará o túto čiastočnú automatizáciu a vie vykonávať lokalizáciu, zabáčanie, rozpoznávanie značiek, brzdenie, detekciu slepého bodu a veľa ďalších. Človek stále monitoruje všetky úkony a vie prevziať kontrolu ľubovoľne [13]. Teraz sa dostávame k bodu, kde prevažne systém monitoruje prostredie jazdy. Štvrtá úroveň pozostáva z podmienennej automatizácie. Auto má schopnosť detekovať prostredie a vie robiť väčšinu jazdných úkonov, napr. predbehnúť pomaly pohybujúce vozidlo, ale ľudské schvaľovanie jazdných úkonov auta a prípadne zakročenie je nutné. Piata úroveň je vysoká automatizácia. Systém ovláda všetky operácie jazdy pod určitými podmienkami, napr. systém má povolené prevziať kontrolu nad vozidlom iba v mestských častiach, kde sa neprekračuje rýchlosť 50km/h. Geofencing¹ je nevyhnutný a ľudské zasiahnutie je stále možnosťou. Šiesta úroveň reprezentuje úplnú automatizáciu, kde auto ovláda všetky úkony pod hocíjakými podmienkami a ľudská pozornosť nie je vôbec vyžadovaná a ľudská interakcia nie je možná [18]. Tabuľka nižšie prehľadne spracúva úrovne automatizácie aut [1].

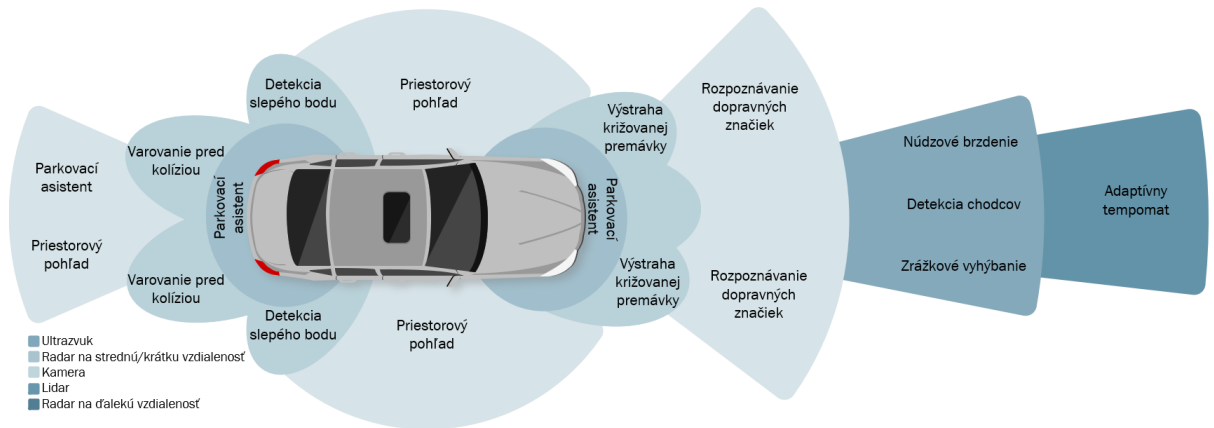
3 Advanced Driver Assistance Systems

Podľa uvedenej štatistiky[1] vieme, že skoro všetky autonehody sú zapríčinené ľudskou chybou. Vďaka ADAS-u (Advanced Driver Assistance Systems) vieme tieto škody redukovať. ADAS obsahuje základné bezpečnostné aplikácie, ku ktorým patrí detekcia a vyhýbanie chodcov, varovanie a oprava vybočenia z jazdného pruhu, rozpoznávanie dopravných značiek, núdzové brzdenie a detekcia slepého bodu. [14] ADAS toto všetko zvláda vďaka jeho najnovším štandardom rozhrania. Používa viacero algoritmov založených na videní, ktoré v realnom čase podporujú subsystémy multimédií, spoločného spracovania videnia a syntézy senzorov. [14]

¹Použitie technológií GPS alebo RFID na vytvorenie virtuálnej geografickej hranice, ktorá umožňuje softvéru spustiť reakciu, keď zariadenie vstúpi alebo opustí konkrétnu oblasť.

3.1 Fungovanie systému ADAS

ADAS [13] vykonáva svoje funkcie pomocou autonómnych aplikačných riešení. Autonómne aplikačné riešenia sú rozčlenené do rôznych čipov, ktoré sa volajú SoC². Tieto čipy zlučujú senzory s akčnými členmi pomocou rozhraní a vysoko výkonných ECU³. Samoriadiace autá používajú niekoľko takýchto aplikácií a technológií na získanie 360-stupňového videnia, ktoré sa sústreďujú aj na blízke a aj na ďaleké okolie [13] (znázornené na diagrame 3.1). ADAS systémy sa stále aktívne zdokonaľujú s pomocou tzv. vnoreného videnia. Implementácia kamier do vozidla tiež zahŕňa funkciu umelej inteligencie, ktorá pomocou sensorovej fúzie⁴ rozpoznáva a spracúva objekty [13]. Táto umelá inteligencia a sensorová fúzia pracujú podobne ako ľudský mozog pri spracúvaní informácií. Kombinujú sa veľké množstvá údajov vďaka softvéru na rozpoznávanie obrazu, ultrazvukových senzorov, lidar a radaru [3.3]. Umelá inteligencia vie analyzovať video v reálnom čase, rozpoznať všetky objekty, a vymerať požadovanú reakciu na okolie. Táto technológia vie reagovať rýchlejšie, ako by dokázal ľudský vodič.



Obr. 1: ADAS - senzorové vnímanie autonómneho vozidla [1]

3.2 Funkcie ADAS systému

Adaptívny tempomat je najmä užitočný na diaľnici. Tento systém sleduje svoju rýchlosť a rýchlosť ostatných vozidiel na diaľnici na neobmedzenú dobu, kde človeku to robí problém po pár minútach. Aplikácia dokáže zrýchliť, spomaliť a vie aj zastaviť vozidlo v závislosti od akcií iných objektov v bezprostrednej blízkosti. [13]

Diaľkové a pixelové svetlo bez oslnenia využíva senzory na prispôbenie sa tme a okoliu vozidla bez rušenia protiidúcich vozidiel. Táto nová aplikácia svetlomietov zisťuje, že či sa vyskytujú oproti autu svetlá iných vozidiel a presmeruje svetlá vozidla preč. Vďaka tomuto úkonu zabráni dočasnému oslepeniu

²Integrovaný obvod, ktorý spája všetky alebo väčšinu komponentov počítača alebo iného elektrického systému.

³Vstavaný systém v automobilovej elektronike, ktorý spravuje jeden alebo viac elektrických systémov alebo subsystémov.

⁴Proces kombinovania senzorických údajov, aby výsledná informácia mala menšiu neistotu.

ostatných účastníkov cestnej premávky. [13]

Adaptívne ovládanie svetiel svetlomety vozidla prispôsobuje vonkajším svetelným podmienkam. Mení smer, rotáciu a silu svetiel v závislosti od prostredia vozidla a tmy. [13]

Autonómne parkovanie je nová technológia, ktorá funguje prostredníctvom sieťovania senzorov vozidla, sieťovej komunikácie 5G, s cloudovými službami, ktoré spravujú autonómne vozidlá na parkoviskách. Sensory vozidiel poskytujú vozidlu informácie o tom, kde sa nachádza, kam musí ísť a ako sa tam bezpečne dostať. Všetky tieto informácie sú metodicky vyhodnocované a používané pri akcelerácii jazdy, brzdení a riadení až do bezpečného zaparkovania vozidla. [13]

Navigačný systém poskytujú hlasové pokyny a "heads up"⁵ displej, ktoré pomáhajú vodičom sledovať trasu a zároveň sa sústrediť na cestu. Tieto navigačné systémy dokážu zobraziť presné dopravné údaje a v prípade potreby naplánovať novú trasu, aby sa šofér vyhol dopravnej zápchke. [13]

Systémy nočného videnia umožňujú vodičom vidieť veci, ktoré by inak bolo ťažké až nemožné vidieť v noci. Existujú dve kategórie implementácie nočného videnia. Aktívne systémy nočného videnia premietajú infračervené svetlo a pasívne systémy sa spoliehajú na teplo, ktoré vyžarujú autá, zvieratá a iné predmety. [13]

Monitorovanie slepého bodu sa využíva na poskytovanie dôležitých informácií vodičom, ktoré je inak ťažké až nemožné získať. Toto monitorovanie prebieha vďaka radaru, ktorý tento bod monitoruje a ako varovný signál pre vodiča sa spustí alarm. [13]

Automatické núdzové brzdenie využíva senzory ako Lidar na zistenie, či vodič práve ide naraziť do iného vozidla alebo iných predmetov na ceste. Táto aplikácia meria vzdialenosť premávky v okolí a upozorňuje vodiča na akékoľvek nebezpečenstvo. Systémy núdzového brzdenia preventívne uťahujú bezpečnostné pásy, znižujú rýchlosť a adaptívne riadia, aby sa predišlo kolízii. [13]

Detekcia ospalosti vodiča varuje vodiča pred ospalosťou alebo inými rušivými vplyvmi na ceste. Sensory analyzujú pohyb hlavy vodiča, pohyb očí a srdcovú frekvenciu na zistenie náznakov ospalosti. V niektorých prípadoch auto vykoná úkon úplného zastavenia vozidla. [13]

Systém monitorovania vodičov pracuje tak, že kamerové senzory dokážu analyzovať, či vodičove oči upriamujú pozornosť na cestu alebo nie. Systémy vedia upozorniť vodiča zvukmi, volantovými vibráciami alebo blikajúcimi svetlami. [13]

3.3 Senzory systému

RADAR vysiela rádiové vlny na detekciu objektov a presný odhad ich rýchlosti. Používa funkciu nazývanú radiálna rýchlosť na meranie zmien vlnových frekvencií, aby sa zistilo, či sa niečo pohybuje smerom k nej alebo preč. Je menej náročný na dáta ako väčšina senzorov a funguje veľmi dobre v hustej hmle, daždi alebo snehu. [8]

LIDAR využíva infračervené senzory na meranie vzdialenosti medzi cieľovým objektom a senzormi s dosahom až 200 metrov. Toto funguje na báze detekcie svetla a merania vzdialenosti. Sensory vysielať vlny a merajú čas, ktorý trvá, kým sa vlny odrazia od objektu a vrátia sa späť. Vytvára presnú 3D mapu oko-

⁵Heads up displej zobrazuje informácie a dáta na čelné sklo auta.

lia vozidla a funguje dobre pri slabom osvetlení. [8]

Video kamery zaznamenávajú viacero statických záberov na zachytenie dvoj-rozmerného filmu. Poskytuje farby, kontrast a optické rozpoznávanie znakov. [8]

Ultrazvukové snímače používajú vysokofrekvenčné zvukové vlny na meranie vzdialenosti medzi objektmi. Sú veľmi presné na krátke vzdialenosti a fungujú dobre v hustej hmle, daždi a za všetkých svetelných podmienok. [8]

Zotrvačná meracia jednotka (IMU) je kombinácia akcelerometrov a gyro-skopov, ktoré určujú lineárny a uhlový pohyb vozidla. Poskytuje spätnú väzbu o skutočnom pohybe vozidla a funguje za každých podmienok. [8]

Globálny navigačný satelitný systém (GNSS) využíva satelity na poskytovanie autonómneho geopriestorového určovania polohy. GPS je iba podmnožinou GNSS. Má celosvetové pokrytie a má prevádzku za každého počasia. Poskytuje polohu medzi vozidlami, ktoré sa navzájom nevidia a tiež keď nie sú viditeľné žiadne dopravné značky alebo čiary. [8]

Samozrejme tieto senzory majú aj svoje nevýhody, ale vďaka sensorovej fúzii sa tieto nevýhody strácajú vďaka kombinovaniu všetkých sensorových vstupov, kde ich podržia iné senzory.

4 Ako operuje autonómne auto

ADAS[3] je len asistent pri šoférovaní vozidla, ktorý poskytuje niekoľko autonómnych funkcií, ale to dostačuje iba pre tretiu úroveň automatizácie jazdy. Ďalej sa článok bude zaoberať úplnou automatizáciou jazdy.

Samoriadenie auta sa musí rozdeliť do štyroch významných kategórií, aby sa vedelo správne popísať jeho priebeh navigovania sa na ceste, ktoré sú: vizualizácia, lokalizácia, plánovanie a ovládanie.

4.1 Vizualizácia

Auto na vizualizovanie svojho okolia potrebuje skombinovať všetky informácie zo všetkých sensorov na ňom rozmiestnených. Tieto informácie sa kombinujú vďaka sensorovej fúzii, ktorá funguje na báze typu umelej inteligencie strojového učenia zvanej "deep learning" (DL)⁶ a vytvorí fúзованé prostredie. [17] Spracovať nespracované dáta takýchto rozmerov je ale strašne komplikované a zložité a preto sa používajú "smart" senzory, ktoré tieto dáta predspracujú a tým sa sensorová fúzia zjednoduší a zefektívnejší. Tieto smart senzory používajú klasické alebo DL algoritmy. Pre príklad článok uvedie RADAR-kamerovú fúziu so smart senzormi, ktoré sú zhotovené pomocou DL algoritmov.

Smart kamerové videnie musí vedieť rozpoznať tri kategórie problémov. Prvá kategória je detekcia jazdného pruhu a členenie cesty. Na prvú kategóriu sa používa LaneNet [16], ktorý delí detekciu jazdného pruhu do dvoch etáp: návrh okraja jazdného pruhu a lokalizácia jazdného pruhu. Do druhej kategórie zapadá detekcia prekážok, dopravných/svetelných značiek a cestných značiek. Na detekovanie týchto vecí sa používa algoritmus YOLO(You Only Look Once) [17], ktorý je jednodušový detektor a predpovedá ohraničujúce rámčeky a vytvára triedené pravdepodobnosti so skórom spoľahlivosti na obrázku v jedinej neurónovej sieti.

⁶Deep learning je trieda algoritmov strojového učenia, ktorá využíva viacero vrstiev na postupné získavanie funkcií vyššej úrovne z nejakého vstupu.

Tretia kategória smart kamerového videnia pozostáva z odhadu vzdialenosti a 3D rekonštrukcie obrazu. Pre túto kategóriu sa používa ModuleNet [4]. Jeho účelom je odhadnúť hĺbku scény výpočtom horizontálnych rozdielov medzi zodpovedajúcimi pixelmi z dvojice obrázkov (tak ako to robia ľudia). Smart RADAR sa zameriava na detekciu prekážok a odhady rýchlosti. Týmto sa zaoberá DL algoritmus "Radar Centric 3D Object Detection" [7]. Všetky tieto informácie zo smart senzorov sa dajú dokopy v neskorej sensorovej fúzii, ktorá používa DP algoritmus FusionNet [10], ktorý predstavuje novú architektúru hlbokéj neurónovej siete na automatickú segmentáciu neurónových štruktúr v konektomických údajoch.

4.2 Lokalizácia

Spracované informácie z vizualizácie a z niektorých ďalších funkcií teraz potrebuje auto využiť na určenie svojej lokality vo svete v reálnom čase. [11] Táto lokalizácia sa delí do troch kategórií, ktoré sa zaoberajú tým, že či systém pozná mapu a začiatočnú pozíciu vozidla. V prvej kategórii systém pozná aj mapu aj začiatočnú polohu. Druhá kategória sa zaoberá tým, že sa mapa pozná, ale nie začiatočná pozícia. Tretia kategória nepozná nič. Článok sa zameria na prvú kategóriu, kde systém pozná aj mapu aj začiatočnú polohu.

Na určenie pozície vo svete používa systém detekciu orientačných bodov. Táto detekcia funguje vďaka systémovému vnímaniu, kde sa používajú výstupy sensorovej fúzie a používajú sa na rozpoznanie rôznych objektov, ktoré tvoria tieto orientačné body. Ďalej sa používa odometria [11], čiže výstupy pohybových smart senzorov na určenie dosiaľ prejdenej vzdialenosti od začiatočnej pozície vozidla. Systém vie určiť túto vzdialenosť, pretože pozná obvod kolesa a koľkokrát sa koleso otočí. Podľa toho počíta prejdenu trasu. Vozidlo potrebuje poznať svoju polohu na centimetre a nie na meter ako u GNSS. Kvôli tomuto bola vytvorená nová technológia nazvaná "kinematika v reálnom čase" (RTK) [6]. RTK-GPS prijíma signály z GNSS spolu s korekčným prúdom, aby sa dosiahla presnosť polohy na centimeter. Nakoniec sa používa ešte ultra široko pásmový radar (UWB) senzor [15], ktorý sa využíva na trilateráciu. Výstupy lokalizácie a vizualizácie sa ďalej spracúvajú v plánovaní.

4.3 Plánovanie

Vozidlo potrebuje teraz podľa výstupov z vizualizácie a lokalizácie predvídať prekážky, predvídať budúce pozície rôznych objektov a ľudí a rozhodovať, plánovať a upravovať trasu z bodu A do bodu B [9]. Sú tri typy takéhoto plánovania: rámcové plánovanie, plánovanie na základe správania okolia a plánovanie cesty. Článok sa zameria na plánovanie podľa správania okolia. V tomto plánovaní trasy sa systém zameriava na dve veci, ktoré sú predvídanie prekážok a rozhodovanie. Predvídanie prekážok sa zostrojuje z výstupov vizualizácie a pomocou strojového učenia založenej na báze Gaussovej regresie procesu [3]. Rozhodovanie autonómneho auta prebieha vďaka DL modelu tzv. "posilnené hlboké učenie" (DRL) [5], ktorý má schopnosť naučiť sa korektne reagovať na správanie prostredia v reálnom čase pre umožnenie bezpečnej navigácie vo všemožných podmienkach.

4.4 Ovládanie

Kategória ovládania v operovaní autonómneho systému, tiež často označovaná ako "riadenie pohybu" alebo "motion control", je procesom premeny zámerov na akcie [9]. Jeho úlohou je realizovať plánované účely poskytnutím potrebných vstupov na hardvérovej úrovni, ktorá bude generovať požadované pohyby. Ovládače mapujú interakciu v reálnom svete z hľadiska sily a energie, zatiaľ čo kognitívne navigačné a plánovacie algoritmy v autonómnom systéme sa zvyčajne zaoberajú rýchlosťou a polohou vozidla vzhľadom na jeho prostredie. Ovládače ďalej generujú uhol natočenia volantu a určité zrýchlenie podľa plánovanej trajektórie a okolitého prostredia [9]. Ovládanie sa delí na dve odvetvia, kde sa používa buď "klasický ovládač" (PID) alebo "predvídavý ovládač" (MPC) [9]. Článok sa zameria na klasický ovládač, ktorý je zatiaľ najzaužívanější v autonómnych autách.

PID ovládač je založený na spätnej väzbe a nevyžaduje žiadny systémový model. Jeho riadiaci poriadok je založený na chybovom signáli:

$$u(t) = k_d \dot{e} + k_p e + k_i \int e(t) dt, \quad (1)$$

kde e je chybový signál a premenné k predstavujú proporcionálne, integrálne a derivačné výstupy ovládača [9]. Vďaka chybovému signálu kontrola spätnou väzbou môže znížiť negatívne vplyvy zmien parametrov, chyby modelovania, ako aj nežiaduce rušenia. Ďalej môže tiež modifikovať prechodné správanie systému, ako aj účinky šumu merania [9]. Samozrejme, ovládač takéhoto typu, ktorý sa spolieha na spätnú väzbu, je limitovaný tým, že má zpozdennú reakciu, pretože na chyby reaguje len vtedy, keď sa vyskytnú. Tento problém sa ošetruje pridaním termínu tzv. "doprednej" väzby a pomáha prekonať obmedzenia spätnej väzby [9]. Ďalej sa implementujú ešte rôzne zložité algoritmy na odstránenie nedostatkov systému, ale napriek tomu sa technológia začína posúvať k DP ovládačom, kde sa používajú End2End a DRL softvérové modely [9].

Spoločenské súvislosti

Historické súvislosti

Technológia a ľudia

5 Záver

Článok uviedol predstavu, ako to vyzerá v softvéri autonómneho auta, ale veľa vecí bolo preskočených, zjednodušených a vynechaných. Rozpracoval úrovne automatizácie, zhruba načrtol ako funguje systém ADAS, funkcie tohto systému a jeho senzory. Ďalej bol veľmi zjednodušene uvedený životný cyklus softvéru plne autonómneho auta, ale vytýčené boli len najzaužívanější aspekty tohto systému a jeho operovania v priestore a aj tieto aspekty veľmi elementárne vysvetlené. Ďalšia verzia článku by bola rozpracovaná hlbšie okolo sensorovej fúzie, všetkých jej typoch a rôznych softvéroch, ktoré umožňujú vizualizáciu autonómneho auta. To isté platí aj pre všetky typy lokalizácie a lokalizačné softvéry, senzory a siete zaužívané v tomto procese. Hlbšie preskúmané umelé inteligencie a rôzne

softvéry, ktoré plánujú a rozhodujú nad reakciou na prostredie v samoriadiacom systéme auta. Určite by sa širšie tiež rozpracovala časť ovládania a ovládačov systému autonómneho auta. Úlohou tohto článku bolo len poskytnúť prehľad o týchto komplikovaných zariadeniach a lepšie pochopiť zložitosť ich softvérového inžinierstva.

Literatúra

- [1] ARCCA. Adas and vehicle autonomy. <https://arcca.com/capabilities/engineering/accident-reconstruction/technology/adas-vehicle-autonomy/>.
- [2] T. English. How do self-driving cars work? <https://interestingengineering.com/how-do-self-driving-cars-work>.
- [3] L. Hewing, J. Kabzan, and M. N. Zeilinger. Cautious model predictive control using gaussian process regression. <https://arxiv.org/pdf/1705.10702.pdf>.
- [4] R.-V. O. I., C.-T. J. C., R.-F. A., and M. Rivera. Modulenet: A convolutional neural network for stereo vision. In K. M. Figueroa Mora, J. Anzuarez Marín, J. Cerda, J. A. Carrasco-Ochoa, J. F. Martínez-Trinidad, and J. A. Olvera-López, editors, *Pattern Recognition*, Cham, 2020. Springer International Publishing.
- [5] D. Isele, R. Rahimi, A. Cosgun, K. Subramanian, and K. Fujimura. Navigating occluded intersections with autonomous vehicles using deep reinforcement learning. https://arxiv.org/pdf/1705.01196.pdf?source=post_page-----.
- [6] R. B. Langley. Rtk gps. <http://www2.unb.ca/gge/Resources/gpsworld.september98.pdf>.
- [7] S. Lee. Deep learning on radar centric 3d object detection. <https://arxiv.org/abs/2003.00851>.
- [8] P. J. Leiss. The functional components of autonomous vehicles - expert article. <https://www.robsonforensic.com/articles/autonomous-vehicles-sensors-expert>.
- [9] S. D. Pendleton, H. Andersen, X. Du, X. Shen, M. Meghjani, Y. H. Eng, D. Rus, and M. H. Ang. Perception, planning, control, and coordination for autonomous vehicles. *Machines*, 5(1), 2017.
- [10] T. M. Quan, D. G. C. Hildebrand, and W.-K. Jeong. Fusionnet: A deep fully residual convolutional neural network for image segmentation in connectomics. <https://arxiv.org/abs/1612.05360>.
- [11] T. G. R. Reid, R. C. Sarah E. Houts, G. Mills, S. Agarwal, A. Vora, and G. Pandey. Localization requirements for autonomous vehicles. <https://arxiv.org/abs/1906.01061>.

- [12] S. Singh. Critical reasons for crashes investigated in the national motor vehicle crash causation survey. Technical report, Mathematical Analysis Division of the National Center for Statistics and Analysis, NHTSA, March 2018.
- [13] Synopsys. What is advanced driver assistance systems? <https://www.synopsys.com/automotive/what-is-adas.html>.
- [14] Synopsys. What is an autonomous car? <https://www.synopsys.com/automotive/what-is-autonomous-car.html>.
- [15] J. D. Taylor. Ultra-wideband radar technology. https://books.google.sk/books?hl=sk&lr=&id=IoW1DwAAQBAJ&oi=fnd&pg=PA1&dq=ultra+wide+band&ots=VKAVbbvL7g&sig=qZtHaNZ5m2ZWwEa0elrR7DZMGt0&redir_esc=y#v=onepage&q&f=false.
- [16] Z. Wang, W. Ren, and Q. Qiu. Lanenet: Real-time lane detection networks for autonomous driving. <https://arxiv.org/abs/1807.01726>.
- [17] D. J. Yeong, G. Velasco-Hernandez, J. Barry, and J. Walsh. Sensor and sensor fusion technology in autonomous vehicles: A review. Technical report, IMaR Research Centre, Munster Technological University, V92 CX88 Tralee, Ireland, 2021.
- [18] T. Yigitcanlar, A. Faisal, M. Kamruzzaman, and G. Currie. Understanding autonomous vehicles. Technical report, Journal of Transport and Land Use, January 2019.